

Roadmap — Predição de Acidentes de Trânsito (IC)

Status geral: 🟡 Em andamento — Etapa 2

Fontes de dados confirmadas: PRF (acidentes) · DNIT (qualidade do pavimento) · INMET (clima) **Unidade de análise final:** trecho de rodovia federal pavimentada + mês **Modelos planejados (nesta ordem):** Regressão Logística → Random Forest → Gradient Boosting/XGBoost (+ K-Means para clustering de trechos) **Ambiente:** Google Colab

Etapa 1 — Explorar SÓ o PRF 🟢 concluída

Objetivo: entender a granularidade real do dado antes de tocar nas outras bases.

- ✓ Baixar CSVs do PRF (2021–2025)
- ✓ Carregar no Colab com pandas
- ✓ Ver quantidade de linhas e colunas — 30 colunas; 2021: 64567, 2022: 64606, 2023: 67766, 2024: 73156, 2025: 72529 linhas
- ✓ Confirmar: 1 linha = 1 acidente? Sim
- ✓ Confirmar: existe coluna de rodovia + km + data? Sim — `br`, `km`, `data_inversa`; também temos `latitude`/`longitude` exatas
- ✓ Concatenar os 5 anos num único DataFrame
- ✓ Corrigir tipos: `km`, `latitude`, `longitude` (vírgula→ponto, texto→float); `data_inversa` (texto→datetime)
- ✓ Checar duplicados, nulos, distribuição por ano — tudo limpo

Notas importantes:

- Base tem campo próprio `condicao_meteorologica`, mas é categórico/qualitativo (percepção do policial), não medição — por isso mantemos INMET como fonte de clima numérica, não este campo.
 - Temos lat/long exatas por acidente — possível alternativa/complemento ao casamento por km de trecho na Etapa 3, a avaliar.
 - Colunas-chave confirmadas para cruzar com DNIT/INMET: `br`, `km`, `uf`, `data_inversa` (+ `latitude`/`longitude` como opção)
-

Etapa 2 — Aprender o mínimo de pandas necessário 🟢 concluída

- ✓ Ler CSV (`pd.read_csv()`)
- ✓ Filtrar linhas (`df[df['coluna']==valor]`)
- ✓ Agrupar e contar (`groupby().count()`, `value_counts()`)
- ✓ Ver valores únicos / resumo de coluna (`value_counts()`)
- ✓ Extrair partes de data (`.dt.month`, `.dt.year`)
- ❑ Juntar tabelas (`merge`) — fica pendente, só faz sentido aprender com a Etapa 3 em mãos (precisa de 2 tabelas)

Recursos usados: exploração direta no próprio dataset do PRF (rodovias com mais acidentes, condição meteorológica, distribuição por mês/UF).

Etapas 3 — Baixar e explorar o DNIT ● (atual) ○

- ☐ Baixar índice de condições de pavimento
 - ☐ Entender granularidade: DNIT é por TRECHO (km inicial-final), não por km exato
 - ☐ Definir lógica: "acidente no km X cai em qual trecho do DNIT?"
-

Etapas 4 — Baixar e explorar o INMET ○

- ☐ Baixar dados históricos das estações relevantes
 - ☐ Definir: qual estação representa qual trecho? (por UF, ou por proximidade geográfica)
-

Etapas 5 — Montar a tabela final (trecho + mês) ○

- ☐ Uma linha = 1 trecho + 1 mês
 - ☐ Colunas de features: índice DNIT, clima médio do mês (INMET)
 - ☐ Coluna target: nº de acidentes no trecho naquele mês (PRF)
 - ☐ Esse é o dataset processado que alimenta o modelo
-

Etapas 6 — Machine Learning ○

- ☐ Baseline: Regressão Logística (train_test_split, treinar, medir acurácia)
 - ☐ Random Forest
 - ☐ Gradient Boosting / XGBoost
 - ☐ K-Means (clustering de trechos similares)
 - ☐ Comparar performance entre modelos
-

Decisões já tomadas (não reabrir sem motivo técnico novo)

- Clima: **INMET**, não API externa (dado oficial, mais citável no artigo)
- Fonte de qualidade de rodovia: **DNIT**, não CNT
- Unidade de análise: trecho pavimentado + mês (não por acidente individual)

Legenda

● em andamento · ○ não iniciado · ● concluído